Université de Bordeaux
L3 Ingénierie Mathématique – Groupe de Travail Applicatif

Gestion optimale d'une forêt

Contrôle impulsionnel, lois invariantes et apprentissage par renforcement

Encadrant : Adrien Richou
Adrien.Richou@u-bordeaux.fr

Année universitaire 2025–2026

Ce rapport s'appuie sur l'étude numérique du modèle proposé dans :

Nonparametric learning for impulse control problems
S. Christensen, C. Strauch, *arXiv:1909.09528v3*, 2022.

Contents

1 Introduction et présentation du problème **2**
1.1 Contexte 2
1.2 Présentation des variables et paramètres 2

2 Modélisation par équation différentielle stochastique **3**
2.1 L'équation différentielle stochastique 3
2.2 Les deux modèles de dérive étudiés 4
2.3 Les deux modèles de diffusion étudiés 4
2.4 Discrétisation numérique 5
2.5 Influence du pas de temps 5

3 Rappels sur la loi normale et calcul de lois invariantes **6**
3.1 Loi normale : définition et propriétés 6
3.2 Loi invariante d'une diffusion 6
3.3 Calcul analytique de la loi invariante pour le modèle 1a 7

4 Théorème ergodique et convergence vers la loi invariante **9**
4.1 Ergodicité des diffusions 9
4.2 Estimation non paramétrique de la densité invariante 10

5 Contrôle optimal pour une dérive connue **10**
5.1 Formulation du problème de contrôle 10
5.2 La fonction ξ_b et l'optimalité des stratégies à seuil 11
5.3 Application numérique 12

6 Apprentissage par renforcement : exploration et exploitation **12**
6.1 Le dilemme exploration-exploitation 12
6.2 La stratégie alternante proposée par Christensen et Strauch 12
6.3 Quantification du regret 13

7 Résultats numériques **14**
7.1 Simulation des trajectoires 14
7.2 Vérification de la loi invariante pour le modèle 1a 14
7.3 Estimation de la loi invariante pour les autres scénarios 14
7.4 Optimisation numérique du seuil de coupe 15

8 Conclusion **15**

A Code Python du notebook **16**

1 Introduction et présentation du problème

1.1 Contexte

La gestion durable d'une ressource naturelle renouvelable soulève une question d'optimisation fondamentale : à quel moment faut-il intervenir pour récolter la ressource, de façon à maximiser le bénéfice économique sur le long terme ? Ce projet s'inscrit dans le cadre du problème de Faustmann stochastique, classique en économie des ressources naturelles, que l'on adapte ici à la gestion d'une forêt.

La ressource est ici le volume de bois exploitable dans une forêt. Ce volume évolue de façon aléatoire au cours du temps sous l'effet conjugué de la croissance biologique et de perturbations imprévisibles (tempêtes, maladies, variations climatiques). Une opération de coupe entraîne des frais fixes, ce qui rend toute politique de coupe permanente économiquement inefficace. L'objectif est donc de déterminer un *seuil de coupe optimal* $y^* > 0$: on laisse la forêt croître jusqu'à ce que le volume de bois atteigne ce seuil, puis on récolte.

La difficulté centrale est que la dynamique de croissance est en pratique inconnue. L'article de référence de Christensen et Strauch [1] propose une stratégie d'apprentissage par renforcement pour traiter ce problème : on alterne des phases d'exploration (on observe la forêt sans couper, pour apprendre la dynamique) et des phases d'exploitation (on applique la stratégie de coupe estimée). Ce rapport présente l'étude numérique de ce modèle, en fournissant les démonstrations mathématiques sous-jacentes.

1.2 Présentation des variables et paramètres

Tout au long de ce rapport, les notations suivantes sont utilisées de façon cohérente.

X_t Volume de bois exploitable dans la forêt à l'instant $t \geq 0$, exprimé dans une unité arbitraire. C'est le processus stochastique principal.

$b : \mathbb{R} \to \mathbb{R}$ Fonction de dérive, qui modélise la tendance moyenne de croissance (ou de décroissance) du volume de bois. Cette fonction est *inconnue en pratique.*

$\sigma : \mathbb{R} \to \mathbb{R}_+^*$ Fonction de diffusion, qui modélise l'intensité des fluctuations aléatoires.

W_t Mouvement brownien standard, représentant l'aléa non modélisable.

$h > 0$ Pas de temps de discrétisation utilisé dans les simulations numériques.

ε_k Variables aléatoires indépendantes de loi gaussienne centrée réduite $\mathcal{N}(0, 1)$, utilisées pour simuler le bruit.

$y^* > 0$ Seuil de coupe optimal.

$p > 0$ Prix de vente d'une unité de bois.

$k > 0$ Frais fixes engendrés par chaque opération de coupe.

$g(y)$ Gain net réalisé lors d'une coupe intervenant quand le volume de bois atteint y. On a $g(y) = py - k$ dans notre modélisation simple.

$\xi_b(y)$ Temps moyen d'attente avant que le processus, partant de 0, atteigne le niveau y (voir Section 5).

ρ_b Densité de la loi invariante (ou stationnaire) du processus X, qui caractérise la distribution à long terme du volume de bois.

$\Phi(b)$ Valeur optimale du taux de profit moyen par unité de temps, pour une dérive b connue.

T Horizon de temps total de la simulation ou de la stratégie d'apprentissage.

S_T Temps total passé en phase d'exploration jusqu'à l'horizon T.

Dans les simulations numériques, les valeurs suivantes ont été utilisées pour les paramètres :

Paramètre	Notation	Valeur
Capacité maximale de la forêt	ℓ	100
Vitesse de retour vers ℓ	λ	0.5
Intensité de l'aléa constant	σ_0	5
Volume initial	X_0	10
Pas de temps	h	0.01
Frais fixes de coupe	k	10
Prix unitaire du bois	p	1

2 Modélisation par équation différentielle stochastique

2.1 L'équation différentielle stochastique

En l'absence d'intervention humaine, l'évolution du volume de bois X_t est modélisée par une *équation différentielle stochastique* (EDS) d'Itô :

$$\mathrm{d}X_t = b(X_t)\,\mathrm{d}t + \sigma(X_t)\,\mathrm{d}W_t, \tag{1}$$

où :

- Le terme $b(X_t)\,\mathrm{d}t$ est la **partie déterministe** (ou dérive) : il décrit la tendance

moyenne de croissance de la forêt.

- Le terme $\sigma(X_t)\,\mathrm{d}W_t$ est la **partie stochastique** (ou diffusion) : il modélise les perturbations aléatoires imprévisibles.
- W_t est un **mouvement brownien standard**, c'est-à-dire un processus stochastique à trajectoires continues, à accroissements indépendants et stationnaires, avec $W_0 = 0$ et $W_t - W_s \sim \mathcal{N}(0, t-s)$ pour $s < t$.

L'intégrale stochastique $\int_0^t \sigma(X_s)\,\mathrm{d}W_s$ est une intégrale d'Itô, dont la définition rigoureuse dépasse le cadre de ce rapport. On retiendra que les accroissements $\sigma(X_s)\,\mathrm{d}W_s$ se comportent heuristiquement comme $\sigma(X_s)\sqrt{\mathrm{d}t} \cdot Z$ où $Z \sim \mathcal{N}(0,1)$, ce qui justifie le schéma de discrétisation présenté ci-après.

2.2 Les deux modèles de dérive étudiés

Deux formes de la fonction de dérive b ont été considérées.

Modèle 1 : Dérive de type Ornstein-Uhlenbeck (retour à la moyenne).

$$b_1(x) = \lambda(\ell - x), \tag{2}$$

où $\lambda > 0$ est un taux de rappel et $\ell > 0$ est le volume de bois à l'équilibre. Cette dérive modélise une croissance qui tend à ramener le volume de bois vers la valeur ℓ : si $X_t < \ell$, alors $b_1(X_t) > 0$ et la forêt croît ; si $X_t > \ell$, alors $b_1(X_t) < 0$ et le volume diminue.

Modèle 2 : Dérive logistique.

$$b_2(x) = \lambda x(\ell - x). \tag{3}$$

Ce modèle s'inspire de la croissance logistique en biologie des populations. Pour des valeurs de x faibles, la croissance est proportionnelle au volume de bois présent (les arbres produisent des graines). Pour des valeurs proches de ℓ, la concurrence pour les ressources ralentit la croissance jusqu'à la stopper.

2.3 Les deux modèles de diffusion étudiés

Modèle a : Diffusion constante.

$$\sigma_a(x) = \sigma_0, \tag{4}$$

où $\sigma_0 > 0$ est une constante. L'intensité de l'aléa est la même quelle que soit la quantité de bois présente. Ce modèle correspond au processus d'Ornstein-Uhlenbeck lorsqu'il est combiné avec la dérive b_1.

Modèle b : Diffusion proportionnelle à $\sqrt{|x|}$.

$$\sigma_b(x) = \sigma_0\sqrt{|x|}. \tag{5}$$

Ici, l'intensité des fluctuations augmente avec le volume de bois. Ce modèle s'inspire de l'hypothèse de volatilité proportionnelle utilisée en finance (modèle de Cox-Ingersoll-Ross). Il produit des trajectoires plus variables lorsque la forêt est dense.

La combinaison des deux dérives et des deux diffusions donne quatre scénarios : 1a, 1b, 2a et 2b.

2.4 Discrétisation numérique

L'EDS (1) est une équation en temps continu, que l'on ne peut pas simuler exactement. On utilise le **schéma d'Euler-Maruyama**, qui discrétise le temps avec un pas $h > 0$ et approche $X_{(k+1)h}$ par :

$$\tilde{X}_{(k+1)h} = \tilde{X}_{kh} + b(\tilde{X}_{kh}) \cdot h + \sigma(\tilde{X}_{kh}) \cdot \sqrt{h} \cdot \varepsilon_{k+1}, \tag{6}$$

où $(\varepsilon_k)_{k\geq 1}$ est une suite de variables aléatoires indépendantes de loi $\mathcal{N}(0,1)$.

Remarque 2.1. La justification de ce schéma est la suivante : sur l'intervalle $[kh, (k+1)h]$, on approche le brownien par un accroissement gaussien $W_{(k+1)h} - W_{kh} \sim \mathcal{N}(0,h)$, et on gèle les coefficients b et σ à leur valeur au début de l'intervalle. On obtient ainsi $\tilde{X}_{(k+1)h} - \tilde{X}_{kh} \approx b(\tilde{X}_{kh}) \cdot h + \sigma(\tilde{X}_{kh}) \cdot \sqrt{h} \cdot \varepsilon_{k+1}$. La loi $\mathcal{N}(0,h)$ est simulée comme $\sqrt{h} \cdot \varepsilon$ avec $\varepsilon \sim \mathcal{N}(0,1)$ (voir Section 3.1).

Pour garantir la positivité du volume de bois, on tronque : $\tilde{X}_{(k+1)h} \leftarrow \max(\tilde{X}_{(k+1)h}, 0)$.

2.5 Influence du pas de temps

La stabilité numérique du schéma d'Euler-Maruyama dépend du pas h. Pour le modèle 1a, la dérive est linéaire $b_1(x) = \lambda(\ell - x) = \lambda\ell - \lambda x$. En linéarisant autour de l'équilibre ℓ, le schéma devient localement :

$$\tilde{X}_{(k+1)h} - \ell \approx (1 - \lambda h)(\tilde{X}_{kh} - \ell) + \sigma_0\sqrt{h}\,\varepsilon_{k+1}.$$

La partie déterministe est stable si et seulement si $|1 - \lambda h| < 1$, c'est-à-dire $h < 2/\lambda$. Avec $\lambda = 0.5$, la condition de stabilité est $h < 4$.

Les simulations confirment ce résultat : pour $h = 4.1 > 2/\lambda$, les trajectoires divergent, tandis que pour $h = 0.01$ ou $h = 0.5$, elles convergent vers la loi stationnaire. Ce résultat illustre l'importance du choix du pas de temps dans les simulations d'EDS.

3 Rappels sur la loi normale et calcul de lois invariantes

3.1 Loi normale : définition et propriétés

Définition 3.1 (Loi normale)**.** Une variable aléatoire réelle Z suit une **loi normale** (ou gaussienne) de moyenne $\mu \in \mathbb{R}$ et de variance $\sigma^2 > 0$, noté $Z \sim \mathcal{N}(\mu, \sigma^2)$, si sa densité de probabilité est :

$$f_Z(z) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right), \quad z \in \mathbb{R}.$$

La loi $\mathcal{N}(0,1)$ est appelée **loi normale centrée réduite** et sa densité est notée $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$.

Proposition 3.1 (Règles de calcul sur la loi normale)**.** *Soient $Z \sim \mathcal{N}(\mu, \sigma^2)$ et $a, b \in \mathbb{R}$ avec $a \neq 0$. Alors :*

1. ***Transformation affine :*** $aZ + b \sim \mathcal{N}(a\mu + b,\, a^2\sigma^2)$.
2. ***Centrage-réduction :*** $\dfrac{Z-\mu}{\sigma} \sim \mathcal{N}(0,1)$.
3. ***Somme indépendante :*** *Si $Z_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Z_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ sont indépendantes, alors $Z_1 + Z_2 \sim \mathcal{N}(\mu_1 + \mu_2,\, \sigma_1^2 + \sigma_2^2)$.*
4. ***Simulation :*** *Si $U \sim \mathcal{N}(0,1)$, alors $\mu + \sigma U \sim \mathcal{N}(\mu, \sigma^2)$.*

La propriété 4 est fondamentale pour la simulation numérique : elle permet de simuler $\mathcal{N}(\mu, \sigma^2)$ à partir de la loi $\mathcal{N}(0,1)$, ce qui est utilisé dans le schéma d'Euler-Maruyama (6).

3.2 Loi invariante d'une diffusion

Définition 3.2 (Loi invariante)**.** Une mesure de probabilité π sur $\mathbb{R}$ est dite **invariante** (ou **stationnaire**) pour le processus X solution de (1) si, lorsque $X_0 \sim \pi$, alors $X_t \sim \pi$ pour tout $t \geq 0$. Si π admet une densité ρ_b (appelée **densité invariante**), c'est la distribution limite des états du processus sur le long terme.

Sous des conditions appropriées sur b et σ (notamment une hypothèse de stabilisation aux bords, voir [1]), la loi invariante est unique et est caractérisée par la propriété que le **générateur infinitésimal** de X annule sa densité. Formellement, la densité ρ_b doit satisfaire l'**équation de Fokker-Planck stationnaire** :

$$\frac{\mathrm{d}}{\mathrm{d}x}\left[-b(x)\rho_b(x) + \frac{1}{2}\frac{\mathrm{d}}{\mathrm{d}x}\big(\sigma^2(x)\rho_b(x)\big)\right] = 0. \tag{7}$$

En intégrant une fois en x et en imposant la condition de flux nul aux bords (condition de *courant de probabilité nul*), on obtient :

$$-b(x)\rho_b(x) + \frac{1}{2}\frac{\mathrm{d}}{\mathrm{d}x}\big(\sigma^2(x)\rho_b(x)\big) = 0. \tag{8}$$

Proposition 3.2 (Expression analytique de la densité invariante)**.** *Sous les conditions d'existence et d'ergodicité, la densité de la loi invariante de l'EDS* (1) *est donnée par :*

$$\rho_b(x) = \frac{C_{b,\sigma}}{\sigma^2(x)} \exp\left(\int_0^x \frac{2b(y)}{\sigma^2(y)}\,\mathrm{d}y\right), \tag{9}$$

où $C_{b,\sigma} > 0$ est la constante de normalisation assurant $\int_{\mathbb{R}} \rho_b(x)\,\mathrm{d}x = 1$:

$$\frac{1}{C_{b,\sigma}} = \int_{\mathbb{R}} \frac{1}{\sigma^2(u)} \exp\left(\int_0^u \frac{2b(y)}{\sigma^2(y)}\,\mathrm{d}y\right)\,\mathrm{d}u.$$

Proof. L'équation (8) est une équation différentielle du premier ordre en ρ_b. En posant $f(x) = \sigma^2(x)\rho_b(x)$, l'équation devient :

$$-\frac{b(x)}{\sigma^2(x)} f(x) + \frac{1}{2} f'(x) = 0,$$

soit $f'(x) = \frac{2b(x)}{\sigma^2(x)} f(x)$. C'est une équation différentielle ordinaire linéaire homogène du premier ordre, dont la solution générale est :

$$f(x) = f(0) \exp\left(\int_0^x \frac{2b(y)}{\sigma^2(y)}\,\mathrm{d}y\right).$$

En revenant à $\rho_b = f/\sigma^2$, on obtient (9) avec $C_{b,\sigma} = f(0)$, déterminé par la condition de normalisation. □

3.3 Calcul analytique de la loi invariante pour le modèle 1a

Le modèle 1a est défini par $b_1(x) = \lambda(\ell - x)$ et $\sigma_a(x) = \sigma_0$ (constante). Il s'agit du **processus d'Ornstein-Uhlenbeck** (OU).

Calcul de l'intégrale dans l'exponentielle :

$$\int_0^x \frac{2b_1(y)}{\sigma_0^2}\,\mathrm{d}y = \frac{2\lambda}{\sigma_0^2}\int_0^x (\ell - y)\,\mathrm{d}y = \frac{2\lambda}{\sigma_0^2}\left[\ell y - \frac{y^2}{2}\right]_0^x = \frac{2\lambda}{\sigma_0^2}\left(\ell x - \frac{x^2}{2}\right).$$

Expression de la densité non normalisée :

$$\frac{1}{\sigma_0^2}\exp\left(\frac{2\lambda}{\sigma_0^2}\left(\ell x - \frac{x^2}{2}\right)\right) = \frac{1}{\sigma_0^2}\exp\left(\frac{2\lambda\ell x}{\sigma_0^2} - \frac{\lambda x^2}{\sigma_0^2}\right).$$

Mise sous forme canonique gaussienne : En complétant le carré dans l'exponentielle, on écrit :

$$\frac{2\lambda\ell x}{\sigma_0^2} - \frac{\lambda x^2}{\sigma_0^2} = -\frac{\lambda}{\sigma_0^2}\left(x^2 - 2\ell x\right) = -\frac{\lambda}{\sigma_0^2}(x-\ell)^2 + \frac{\lambda\ell^2}{\sigma_0^2}.$$

Ainsi la densité invariante est proportionnelle à :

$$\exp\left(-\frac{\lambda}{\sigma_0^2}(x-\ell)^2\right) = \exp\left(-\frac{(x-\ell)^2}{2\cdot\frac{\sigma_0^2}{2\lambda}}\right).$$

Proposition 3.3 (Loi invariante du processus d'Ornstein-Uhlenbeck)**.** *La loi invariante du modèle 1a est la loi normale :*

$$\rho_{b_1}(x) = \mathcal{N}\left(\ell,\ \frac{\sigma_0^2}{2\lambda}\right),$$

c'est-à-dire une loi normale de moyenne ℓ et de variance $\sigma_\infty^2 = \dfrac{\sigma_0^2}{2\lambda}$.

Proof. D'après le calcul précédent, $\rho_{b_1}(x) \propto \exp\left(-\frac{(x-\ell)^2}{2\sigma_\infty^2}\right)$ avec $\sigma_\infty^2 = \frac{\sigma_0^2}{2\lambda}$, ce qui est précisément la densité de $\mathcal{N}(\ell, \sigma_\infty^2)$. □

Interprétation des paramètres :

- *Moyenne ℓ* : à long terme, le volume de bois oscille autour de la capacité maximale ℓ. La dérive ramène le processus vers ℓ.
- *Variance $\sigma_\infty^2 = \sigma_0^2/(2\lambda)$* : plus le taux de retour λ est grand, plus les fluctuations à long terme sont faibles. Plus le bruit σ_0 est grand, plus la variance stationnaire est grande.

Vérification numérique : Les paramètres du notebook donnent $\lambda = 0.5$, $\ell = 100$, $\sigma_0 = 5$, d'où $\sigma_\infty^2 = 25/(2\times 0.5) = 25$ et $\sigma_\infty = 5$. Les simulations longues du modèle 1a

confirment que l'histogramme des valeurs de (X_t) en régime stationnaire correspond à une loi $\mathcal{N}(100, 25)$.

Correction pour le schéma discret : Le schéma d'Euler-Maruyama introduit un biais. Pour le modèle 1a, la récurrence (6) donne :

$$\tilde{X}_{(k+1)h} = (1 - \lambda h)\tilde{X}_{kh} + \lambda \ell h + \sigma_0 \sqrt{h}\, \varepsilon_{k+1}.$$

À l'équilibre, on calcule la variance stationnaire de ce processus AR(1). Si $\tilde{X}_{kh}$ a pour variance v, alors $\tilde{X}_{(k+1)h}$ a pour variance $(1 - \lambda h)^2 v + \sigma_0^2 h$. À l'équilibre, $v = (1 - \lambda h)^2 v + \sigma_0^2 h$, soit :

$$v = \frac{\sigma_0^2 h}{1 - (1 - \lambda h)^2} = \frac{\sigma_0^2 h}{2\lambda h - \lambda^2 h^2} = \frac{\sigma_0^2}{2\lambda - \lambda^2 h}. \tag{10}$$

Cette expression est utilisée dans le notebook pour vérifier la cohérence des simulations. Pour $h \to 0$, on retrouve bien $\sigma_\infty^2 = \sigma_0^2/(2\lambda)$.

4 Théorème ergodique et convergence vers la loi invariante

4.1 Ergodicité des diffusions

L'ergodicité est la propriété qui assure que les moyennes temporelles convergent vers les espérances théoriques par rapport à la loi invariante. C'est le fondement mathématique qui justifie l'estimation de la loi invariante par simulation longue.

Théorème 4.1 (Théorème ergodique pour les diffusions)**.** *Supposons que l'EDS* (1) *admette une unique loi invariante π de densité ρ_b. Alors, pour toute fonction $f : \mathbb{R} \to \mathbb{R}$ intégrable par rapport à π et pour toute condition initiale $X_0 = x_0$, il vient presque sûrement :*

$$\frac{1}{T}\int_0^T f(X_t)\,\mathrm{d}t \xrightarrow[T\to\infty]{p.s.} \int_{\mathbb{R}} f(x)\rho_b(x)\,\mathrm{d}x = \mathbb{E}_\pi[f(X)].$$

Remarque 4.1. Ce théorème est l'analogue pour les diffusions du théorème ergodique de Birkhoff pour les systèmes dynamiques. Il généralise la loi des grands nombres aux processus continus en temps. La condition d'ergodicité est vérifiée pour les dérives $b \in \Sigma$ introduites par Christensen et Strauch [1], qui imposent notamment que $b(x)/\sigma^2(x) \cdot \operatorname{sgn}(x) \leq -\gamma < 0$ pour $|x|$ grand, garantissant que le processus est ramené vers le centre.

Conséquence pratique pour les simulations : Le Théorème 4.1 justifie l'estimation numérique de la loi invariante par simulation. Pour estimer la densité ρ_b, on simule une longue trajectoire et on construit l'histogramme des valeurs observées après une

période de *chauffe* (les premiers pas de temps, pendant lesquels le processus est encore influencé par la condition initiale, sont ignorés). C'est précisément ce que font les cellules du notebook.

4.2 Estimation non paramétrique de la densité invariante

Au-delà de l'histogramme, Christensen et Strauch [1] utilisent un estimateur à noyau pour estimer ρ_b. Étant données des observations continues $(X_s)_{0\le s\le T}$, l'estimateur à noyau de bande passante $h > 0$ est :

$$\hat{\rho}_T(x) = \frac{1}{Th}\int_0^T Q\left(\frac{x - X_s}{h}\right)\,\mathrm{d}s, \tag{11}$$

où $Q : \mathbb{R} \to \mathbb{R}$ est une fonction noyau symétrique, à support compact, d'intégrale 1. Pour $h = T^{-1/2}$ (choix optimal dans ce contexte), l'erreur quadratique moyenne en norme L^1 décroît comme $T^{-1/2}$:

$$\sup_{b\in\Sigma} \mathbb{E}_b[\|\hat{\rho}_T - \rho_b\|_{L^1}] \le \frac{C}{\sqrt{T}}.$$

Ce taux est dit *paramétrique* : il ne dépend pas de la régularité de la densité (tant que ρ_b est lipschitzienne), grâce à l'observation continue du processus.

5 Contrôle optimal pour une dérive connue

5.1 Formulation du problème de contrôle

Lorsque la forêt atteint un seuil $y > 0$, le gestionnaire procède à une coupe. Le volume de bois est ramené à 0 (la forêt est entièrement récoltée), et un gain $g(y) = py - k$ est encaissé, où k correspond aux frais fixes et p au prix unitaire. On cherche à maximiser le **taux de gain moyen par unité de temps** sur le long terme.

Formellement, une **stratégie à seuil** de niveau y consiste en la suite de temps d'arrêt :

$$\tau_0 := 0, \qquad \tau_n := \inf\{t \ge \tau_{n-1} : X_t \ge y\}, \quad n \ge 1.$$

Le processus X suit l'EDS (1) entre deux coupes et est remis à 0 à chaque temps τ_n. Le critère à maximiser est :

$$\Phi(b) = \sup_{y>0} \liminf_{T\to\infty} \frac{1}{T}\mathbb{E}\left[\sum_{n:\tau_n\le T} g(X_{\tau_n^-})\right], \tag{12}$$

où $X_{\tau_n^-}$ désigne la valeur du processus juste avant la n-ième coupe, qui est égale à y

(par définition du seuil).

5.2 La fonction ξ_b et l'optimalité des stratégies à seuil

Définition 5.1 (Fonction ξ_b)**.** Pour $x > 0$ et une dérive b donnée, on définit :

$$\xi_b(x) := 2\int_0^x \frac{1}{\sigma^2(y)\rho_b(y)} \left(\int_{-\infty}^y \rho_b(z)\,\mathrm{d}z\right) \mathrm{d}y. \tag{13}$$

La fonction ξ_b admet une interprétation probabiliste fondamentale.

Lemme 5.1. *Pour tout $y > 0$, si $\tau_y := \inf\{t \geq 0 : X_t \geq y\}$ désigne le premier temps d'atteinte du niveau y par le processus non contrôlé partant de $X_0 = 0$, alors :*

$$\xi_b(y) = \mathbb{E}_b[\tau_y \mid X_0 = 0]\,.$$

Autrement dit, $\xi_b(y)$ est le ***temps moyen d'attente*** *avant de couper, si l'on utilise la stratégie à seuil y.*

Proof. Ce résultat est une conséquence classique de la théorie des diffusions (voir [1], Lemme 1). Il repose sur le fait que $M_t = \xi_b(X_t) - t$ est une martingale locale pour le processus non contrôlé, ce que l'on vérifie par la formule d'Itô appliquée à ξ_b. □

Ce lemme permet d'interpréter le gain moyen par unité de temps d'une stratégie à seuil y : pendant chaque cycle, on attend en moyenne $\xi_b(y)$ unités de temps pour encaisser un gain $g(y)$. Le taux de gain moyen est donc $g(y)/\xi_b(y)$.

Proposition 5.1 (Optimalité de la stratégie à seuil)**.** *La valeur optimale du problème (12) est :*

$$\Phi(b) = \sup_{y\in[y_1,\zeta]} \frac{g(y)}{\xi_b(y)}, \tag{14}$$

où $y_1 := \inf\{y > 0 : g(y) > 0\}$ est le plus petit niveau rentable et ζ est un niveau supérieur connu au-delà duquel il n'est jamais optimal d'attendre. Le seuil optimal $y^* = y_b^*$ est un maximiseur de $y \mapsto g(y)/\xi_b(y)$.

Proof. (Esquisse) La preuve de la borne supérieure repose sur une inégalité de martingale. Pour tout $\gamma \geq \sup_y g(y)/\xi_b(y)$, la quantité $g(y) - \gamma\xi_b(y) \leq 0$ pour tout y. En appliquant le théorème d'arrêt optimal à la martingale $M_t = \xi_b(X_t) - t$, on montre que le taux de gain de toute stratégie admissible est au plus γ. La stratégie à seuil y^* atteint cette borne (voir [1], Proposition 1). □

5.3 Application numérique

Calcul du seuil optimal pour le modèle 1a. Pour $b_1(x) = \lambda(\ell - x)$, $\sigma_a(x) = \sigma_0$, et $g(y) = py - k$, les simulations montrent que le profit moyen par unité de temps $y \mapsto g(y)/\xi_b(y)$ est une fonction unimodale. Le seuil optimal y^* est celui qui maximise ce rapport. Pour $\lambda = 0.5$, $\ell = 100$, $\sigma_0 = 5$, $p = 1$, $k = 10$, les simulations numériques estiment y^* en balayant une grille de seuils entre 15 et 150.

Les quatre scénarios produisent des seuils optimaux différents, reflétant les différences dans la dynamique de chaque modèle. La dérive logistique (Modèle 2), qui favorise la croissance à des niveaux intermédiaires, tend à produire des seuils optimaux différents de ceux de la dérive linéaire.

6 Apprentissage par renforcement : exploration et exploitation

6.1 Le dilemme exploration-exploitation

Lorsque la fonction de dérive b est inconnue, le seuil optimal $y^* = y_b^*$ ne peut pas être calculé directement. Une stratégie naïve consiste à :

1. Laisser la forêt croître librement pendant une période $[0, T_0]$ pour estimer b (ou sa loi invariante ρ_b).
2. À partir de T_0, utiliser l'estimateur $\hat{y}_{T_0}$ du seuil optimal.

Mais cette stratégie souffre d'un défaut fondamental : si on applique toujours la même stratégie à seuil $\hat{y}$, le processus ne dépasse jamais $\hat{y}$. On ne peut donc pas apprendre la dynamique au-dessus de $\hat{y}$, et si $\hat{y} < y^*$, l'estimateur ne convergera jamais vers la valeur optimale. C'est le **dilemme exploration-exploitation**.

6.2 La stratégie alternante proposée par Christensen et Strauch

Pour résoudre ce dilemme, Christensen et Strauch [1] proposent une stratégie qui alterne des périodes d'exploration et d'exploitation.

Phases d'exploitation : On applique la stratégie à seuil $\hat{y}_{S_t}$ (estimé à partir des observations d'exploration jusqu'au temps S_t). On encaisse des gains.

Phases d'exploration : On laisse la forêt croître librement jusqu'à ce qu'elle atteigne le niveau ζ (borne supérieure connue), puis revienne à 0. On n'encaisse pas de gain, mais on accumule des données pour améliorer l'estimation de ρ_b.

Le temps S_T passé en exploration jusqu'à T doit satisfaire deux conditions contradictoires :

$$S_T \to \infty \quad \text{(pour apprendre)} \qquad \text{et} \qquad \frac{S_T}{T} \to 0 \quad \text{(pour exploiter)}.$$

Le choix optimal est $S_T \approx T^{2/3}$.

6.3 Quantification du regret

Le **regret** cumulé jusqu'à T mesure la perte par rapport à la stratégie optimale (avec b connu) :

$$R_T := \Phi(b) \cdot T - \mathbb{E}\left[\sum_{n:\tau_n \le T} g(X_{\tau_n^-})\right].$$

Théorème 6.1 (Taux de regret optimal, [1])**.** *Avec la stratégie alternante d'exploration-exploitation avec $S_T \asymp T^{2/3}$, le regret cumulé satisfait :*

$$\limsup_{T\to\infty} T^{1/3}\left(\Phi(b) - \frac{1}{T}\mathbb{E}\left[\sum_{n:\tau_n \le T} g(X_{\tau_n^-})\right]\right) \le D,$$

pour une constante $D > 0$ uniforme sur la classe de dérives admissibles Σ. En d'autres termes, le regret moyen par unité de temps est d'ordre $O(T^{-1/3})$.

Proof. (Esquisse de la preuve du Théorème 6.1.) Le regret se décompose en deux termes :

$$R_T \lesssim \underbrace{\Phi(b) \cdot \mathbb{E}[S_T]}_{\text{regret d'exploration}} + \underbrace{\int_0^T \mathbb{E}\left[\Phi(b) - \frac{g}{\xi_b}(\hat{y}^0_{S_t})\right] \mathrm{d}t}_{\text{regret d'exploitation}},$$

où $\hat{y}^0_{S_t}$ est l'estimateur du seuil construit à partir des données d'exploration de durée S_t, et le processus X^0 désigne le processus vu lors des phases d'exploration.

Terme d'exploration : Comme $\mathbb{E}[S_T] \lesssim T^{2/3}$ par hypothèse, ce terme est d'ordre $T^{2/3}$.

Terme d'exploitation : Par la Proposition 5.1, le regret dû à un seuil sous-optimal $\hat{y}$ est contrôlé par $\|\hat{\rho}_T - \rho_b\|_{L^1}$. D'après le taux de convergence de l'estimateur (voir Section 3.2), on a $\mathbb{E}[\Phi(b) - g/\xi_b(\hat{y}^0_s)] \lesssim s^{-1/2}$. Ainsi :

$$\int_0^T \mathbb{E}\left[\Phi(b) - \frac{g}{\xi_b}(\hat{y}^0_{S_t})\right] \mathrm{d}t \lesssim \int_0^T (mt^{2/3})^{-1/2}\,\mathrm{d}t = m^{-1/2}\int_0^T t^{-1/3}\,\mathrm{d}t \lesssim T^{2/3}.$$

En additionnant les deux termes et en divisant par T, on obtient un regret moyen d'ordre $T^{-1/3}$. □

Remarque 6.1. Le choix $S_T \asymp T^{2/3}$ est optimal : il égalise les ordres de grandeur des deux sources de regret (exploration et exploitation). Si l'on choisissait $S_T \asymp T^{\alpha}$ avec $\alpha \neq 2/3$, le regret total serait dominé par l'un des deux termes et serait d'ordre supérieur à $T^{2/3}$.

7 Résultats numériques

7.1 Simulation des trajectoires

Les quatre scénarios (1a, 1b, 2a, 2b) ont été simulés avec $n = 5000$ pas de temps ($h = 0.01$, horizon $T = 50$). Les trajectoires obtenues présentent les comportements attendus :

- **Scénario 1a** (dérive linéaire, bruit constant) : le processus oscille autour de $\ell = 100$ avec une amplitude stationnaire modérée.
- **Scénario 1b** (dérive linéaire, bruit proportionnel) : des oscillations similaires au scénario 1a, mais avec une variance qui augmente avec le niveau, produisant des fluctuations plus importantes près de ℓ.
- **Scénario 2a** (dérive logistique, bruit constant) : la forêt croît rapidement depuis $X_0 = 10$ puis se stabilise près de ℓ avec des oscillations similaires au scénario 1a.
- **Scénario 2b** (dérive logistique, bruit proportionnel) : combinaison des caractéristiques des scénarios 2a et 1b.

7.2 Vérification de la loi invariante pour le modèle 1a

Une simulation longue ($n = 100\,000$ pas, dont les $20\,000$ premiers sont ignorés pour la chauffe) a permis d'estimer la loi invariante du modèle 1a. L'histogramme des valeurs simulées est superposé à la densité théorique $\mathcal{N}(\ell, \sigma_0^2/(2\lambda)) = \mathcal{N}(100, 25)$ (Proposition 3.3).

La concordance entre la distribution simulée et la loi normale théorique est excellente, validant à la fois le modèle et le schéma numérique. La variance discrète calculée selon la formule (10) est $v = \sigma_0^2/(2\lambda - \lambda^2 h) = 25/(1 - 0.0025) \approx 25.06$, très proche de la variance continue 25.

7.3 Estimation de la loi invariante pour les autres scénarios

Pour les scénarios 1b, 2a et 2b, la loi invariante n'admet pas d'expression analytique simple. Les histogrammes obtenus par simulation longue montrent que :

- Le scénario 1b produit une distribution asymétrique, car la diffusion proportionnelle à $\sqrt{|x|}$ amplifie les fluctuations pour les grandes valeurs de x.
- Le scénario 2a produit une distribution concentrée près de $\ell = 100$, car la dérive logistique ramène fortement le processus vers ℓ.
- Le scénario 2b combine les effets des deux, avec une distribution plus étalée.

Dans tous les cas, la distribution empirique peut être approximée visuellement par une loi normale ajustée sur les données, bien que ce ne soit qu'une approximation.

7.4 Optimisation numérique du seuil de coupe

Pour chaque scénario, la fonction $y \mapsto$ profit simulé(y) a été évaluée en balayant 40 valeurs de y entre 15 et 150, avec $n = 50\,000$ pas de simulation par évaluation. Les résultats montrent que :

- La fonction est unimodale pour tous les scénarios, confirmant l'existence d'un seuil optimal unique.
- Le seuil optimal est différent pour chaque scénario, reflétant l'influence de la dynamique sur la stratégie.
- Pour le modèle 1a, le seuil optimal se situe bien au-dessus du niveau minimal rentable $y_1 = k/p = 10$.

Ces résultats illustrent numériquement la Proposition 5.1 : il existe bien un seuil y^* qui maximise le rapport $g(y)/\xi_b(y)$, et la stratégie à seuil correspondante est optimale.

8 Conclusion

Ce projet a permis d'étudier numériquement le modèle de gestion optimale de forêt proposé par Christensen et Strauch [1], en articulant trois axes complémentaires.

Modélisation stochastique. La dynamique de la forêt est modélisée par une EDS d'Itô, discrétisée par le schéma d'Euler-Maruyama. L'étude de l'influence du pas de temps a mis en évidence la condition de stabilité $h < 2/\lambda$.

Lois invariantes. Pour le processus d'Ornstein-Uhlenbeck (modèle 1a), la loi invariante est analytiquement calculable et vaut $\mathcal{N}(\ell, \sigma_0^2/(2\lambda))$. Cette formule est validée par les simulations. Pour les autres modèles, la loi invariante est estimée numériquement par simulation longue, conformément au théorème ergodique.

Optimisation du seuil de coupe. L'existence d'un seuil optimal y^*, solution d'un

problème de maximisation du rapport gain/temps d'attente, est illustrée numériquement. La stratégie à seuil est optimale lorsque la dynamique est connue.

Apprentissage par renforcement. Quand la dérive est inconnue, la stratégie alternante exploration-exploitation avec $S_T \asymp T^{2/3}$ permet d'atteindre un regret d'ordre $O(T^{-1/3})$, résultat remarquable qui ne dépend pas de la régularité de la dérive.

Ce travail illustre comment les techniques de contrôle stochastique et de statistique non paramétrique peuvent être combinées de façon productive, ouvrant la voie à des applications plus générales en gestion durable de ressources naturelles.

References

[1] S. Christensen et C. Strauch, *Nonparametric learning for impulse control problems*, arXiv:1909.09528v3, 2022.

A Code Python du notebook

Cette annexe reproduit l'intégralité du code Python utilisé dans le notebook pour les simulations numériques.

Paramètres globaux et imports

```python
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats

lambd = 0.5      # Vitesse a laquelle la foret repousse vers l
l = 100.0        # Quantite max de bois possible
sigma_val = 5.0 # Force des evenements imprevus
x0 = 10.0        # Quantite de bois presente a l'instant 0

h = 0.01         # Pas de temps
k = 10.0         # Frais fixes a chaque coupe
p = 1.0          # Prix de vente d'une unite de bois
```

Fonctions de dérive et de diffusion

```python
def b(x, modele_b='1'):
    if modele_b == '1':
        return lambd * (l - x)         # Derive Ornstein-Uhlenbeck
    elif modele_b == '2':
        return lambd * x * (l - x)     # Derive logistique
```

```python

def sigma(x, modele_sigma='a'):
    if modele_sigma == 'a':
        return sigma_val              # Diffusion constante
    elif modele_sigma == 'b':
        return sigma_val * np.sqrt(np.abs(x))  # Diffusion
            proportionnelle
```

Schéma d'Euler-Maruyama

```python
def calculer_prochain_pas(x, h, modele_b='1', modele_sigma='a'):
    derive = b(x, modele_b) * h
    bruit = np.random.normal(0, 1)
    diffusion = sigma(x, modele_sigma) * np.sqrt(h) * bruit
    x_suivant = x + derive + diffusion
    return max(x_suivant, 0)   # Truncature pour garantir la positivite

def simuler_trajectoire(n_pas, h, modele_b='1', modele_sigma='a'):
    x = np.zeros(n_pas + 1)
    x[0] = x0
    for i in range(n_pas):
        x[i+1] = calculer_prochain_pas(x[i], h, modele_b, modele_sigma)
    return x
```

Simulation et visualisation des trajectoires

```python
n_pas = 5000
temps = np.linspace(0, n_pas * h, n_pas + 1) * 10

# Scenario 1a : Croissance lineaire, Alea constant
x_1a = simuler_trajectoire(n_pas, h, modele_b='1', modele_sigma='a')
# ... (idem pour 1b, 2a, 2b)
```

Étude de l'influence du pas de temps

```python
h_petit = 0.01
h_moyen = 0.5
h_suplambda = 4.1   # Superieur a 2/lambda = 4 : instable

temps_simulation_max = 100
n_pas_petit    = int(temps_simulation_max / h_petit)
n_pas_moyen    = int(temps_simulation_max / h_moyen)
n_pas_suplambda = int(temps_simulation_max / h_suplambda)

x_petit     = simuler_trajectoire(n_pas_petit,     h_petit,     '1', 'a')
```

```
x_moyen     = simuler_trajectoire(n_pas_moyen,     h_moyen,     '1', 'a')
x_suplambda = simuler_trajectoire(n_pas_suplambda, h_suplambda, '1', 'a')
```

Vérification de la loi invariante (modèle 1a)

```
n_pas_long = 100000
x_long = simuler_trajectoire(n_pas_long, h, '1', 'a')

x_equilibre = x_long[20000:]   # On ecarte la periode de chauffe

# Variance theorique discrete (formule analytique)
variance_th = (sigma_val**2) / (2 * lambd - (lambd**2) * h)
ecart_type_th = np.sqrt(variance_th)

# Superposition de l'histogramme et de la densite gaussienne theorique
plt.hist(x_equilibre, bins=12, density=True, alpha=0.5,
         label="Donnees simulations", edgecolor="black")
x_th = np.linspace(min(x_equilibre), max(x_equilibre), 200)
y_th = stats.norm.pdf(x_th, loc=l, scale=ecart_type_th)
plt.plot(x_th, y_th, 'r-', lw=2, label="Loi Normale th")
```

Optimisation numérique du seuil de coupe

```
def evaluer_profit(y, modele_b='1', modele_sigma='a', n_pas=50000):
    x = x0
    profit = 0.0
    for _ in range(n_pas):
        if x >= y:
            profit += p * x - k     # Gain net : revenu moins frais fixes
            x = 0.0                # La foret est rasee
        x = calculer_prochain_pas(x, h, modele_b, modele_sigma)
    return profit / (n_pas * h)    # Profit moyen par unite de temps

# Balayage de seuils
seuils = np.linspace(15, 150, 40)
profits1a = [evaluer_profit(y) for y in seuils]
# ... (idem pour les autres scenarios)

# Affichage et identification du seuil optimal
posmax1a = np.argmax(profits1a)
plt.axvline(seuils[posmax1a], color='red', linestyle='--',
            label=f"Optimal : {seuils[posmax1a]:.1f}")
```

Estimation et comparaison des lois invariantes (tous scénarios)

```python
def tracer_histogramme(data, titre, couleur, K=100):
    t_recu = np.linspace(0, 50, len(data))
    indices_equilibre = t_recu > 5   # On ignore les 5 premieres unites de temps
    donnees = data[indices_equilibre]

    plt.hist(donnees, bins=50, density=True, color=couleur, alpha=0.6,
             edgecolor='black', label="Donnees simulations")

    moyenne_obs  = np.mean(donnees)
    ecart_type_obs = np.std(donnees)

    # Superposition d'une loi normale ajustee aux donnees
    x_normal = np.linspace(min(donnees), max(donnees), 200)
    y_normal = stats.norm.pdf(x_normal, loc=moyenne_obs, scale=ecart_type_obs)
    plt.plot(x_normal, y_normal, 'orange', lw=2,
             label=f'Loi Normale (sigma={ecart_type_obs:.2f})')

# Application aux quatre scenarios
tracer_histogramme(x_1a, "Loi Invariante (Scenario 1a)", "skyblue")
tracer_histogramme(x_1b, "Loi Invariante (Scenario 1b)", "steelblue")
tracer_histogramme(x_2a, "Loi Invariante (Scenario 2a)", "lightgreen")
tracer_histogramme(x_2b, "Loi Invariante (Scenario 2b)", "forestgreen")
```