Université de Bordeaux
UFR de Mathématiques et Interactions
L3 Ingénierie Mathématique – Groupe de Travail Applicatif

Gestion optimale d'une forêt

Simulation stochastique, contrôle impulsionnel et apprentissage par renforcement

Groupe : Paul Laborde
Thomas Gamot
Paul Da Silva Fernandes
Oscar Huchet
Olivier Dayraut

Encadrant : Adrien Richou
`Adrien.Richou@u-bordeaux.fr`

Année universitaire 2025–2026

Étude numérique du modèle proposé dans :

Nonparametric learning for impulse control problems
S. Christensen, C. Strauch – *arXiv:1909.09528v3*, 2022.

Résumé

Ce projet traite de la gestion optimale d'une forêt exploitée durablement. La quantité de bois disponible est modélisée par une équation différentielle stochastique (EDS). Quatre variantes du modèle sont étudiées, combinant deux lois de croissance (linéaire et logistique) et deux régimes de bruit (constant et proportionnel). L'objectif final est de construire un algorithme d'apprentissage par renforcement capable de déterminer automatiquement le meilleur moment pour couper la forêt, sans connaissance préalable de la dynamique sous-jacente.

Le projet progresse chronologiquement en trois étapes. D'abord, la simulation numérique des trajectoires et l'étude de leur comportement à long terme via les lois stationnaires. Ensuite, en supposant la dynamique connue, le calcul du seuil de coupe optimal qui maximise le profit moyen par unité de temps. Enfin, et c'est l'enjeu central du projet, la conception d'une stratégie alternant phases d'exploration et d'exploitation pour apprendre et contrôler simultanément, dont le regret décroît en $O(T^{-1/3})$ conformément aux résultats de l'article de référence [1].

Mots-clés : équation différentielle stochastique, contrôle impulsionnel, loi invariante, apprentissage par renforcement, exploration-exploitation.

Contents

Résumé **1**

1 Introduction **3**
1.1 Contexte et motivation . . . 3
1.2 Objectifs . . . 3
1.3 Outils mobilisés . . . 3

2 Modèles et simulation **4**
2.1 Modélisation par EDS . . . 4
2.2 Schéma de simulation . . . 4

3 Lois stationnaires **5**
3.1 Comportement à long terme et théorème ergodique . . . 5
3.2 Estimation et résultats . . . 6

4 Contrôle optimal avec dynamique connue **7**
4.1 Formulation du problème . . . 7
4.2 Le seuil optimal et la fonction ξ_b . . . 8
4.3 Résultats numériques . . . 8

5 Apprentissage par renforcement **9**
5.1 Le problème central : apprendre sans connaître b . . . 9
5.2 Estimation de la loi stationnaire et de ξ_b . . . 9
5.3 Stratégie d'alternance et équilibre exploitation-exploration . . . 10
5.4 Algorithme . . . 11
5.5 Corrections apportées et difficultés d'implémentation . . . 11
5.6 Résultats . . . 12

6 Organisation du groupe et retour d'expérience **13**
6.1 Organisation du travail . . . 13
6.2 Difficultés rencontrées . . . 13

7 Conclusion **14**

Annexe – Pseudo-code des fonctions clés **14**

1 Introduction

1.1 Contexte et motivation

On s'intéresse à la gestion durable d'une forêt dont le volume de bois exploitable X_t évolue aléatoirement au cours du temps. Chaque coupe génère un gain, mais entraîne aussi des frais fixes : il n'est donc pas rentable de couper en permanence. La question centrale est : **à quel niveau de bois faut-il couper pour maximiser le gain moyen à long terme ?**

Lorsque la dynamique de croissance est parfaitement connue, ce seuil optimal y^* peut être calculé explicitement. Mais en pratique, le gestionnaire ne connaît pas la loi de croissance de la forêt – il ne peut qu'observer son évolution au fil du temps. Il doit donc *apprendre* cette dynamique tout en continuant à *exploiter* la forêt : c'est le cœur du projet, et c'est précisément le problème traité par Christensen et Strauch [1].

1.2 Objectifs

Le projet suit une progression en trois étapes de complexité croissante, chacune construisant sur la précédente :

1. **Simulation et comportement à long terme.** Comprendre numériquement la dynamique des quatre modèles, simuler leurs trajectoires et caractériser leur distribution stationnaire.

2. **Contrôle optimal avec dynamique connue.** Calculer le seuil de coupe optimal y^* en supposant la fonction de croissance b connue, et vérifier numériquement son optimalité.

3. **Apprentissage par renforcement.** Concevoir et implémenter une stratégie de contrôle entièrement guidée par les données, sans connaissance de b, et évaluer sa performance.

L'étape 3 est l'objectif final du projet. Les étapes 1 et 2 en constituent les fondations indispensables.

1.3 Outils mobilisés

Mathématiques : calcul stochastique (EDS d'Itô), théorie du contrôle impulsionnel ergodique, estimation non paramétrique de densités.

Numérique : discrétisation temporelle d'EDS, intégration numérique par trapèzes, optimisation scalaire.

Informatique : implémentation en Python (`numpy`, `scipy`, `matplotlib`), estimation de densité par `scipy.stats.gaussian_kde`.

2 Modèles et simulation

2.1 Modélisation par EDS

En l'absence de coupe, l'évolution du volume de bois X_t est modélisée par :

$$\mathrm{d}X_t = b(X_t)\,\mathrm{d}t + \sigma(X_t)\,\mathrm{d}W_t, \tag{1}$$

où b est la **dérive** (tendance de croissance), σ la **diffusion** (intensité des aléas), et (W_t) un mouvement brownien standard. Le terme $\sigma(X_t)\,\mathrm{d}W_t$ modélise les perturbations imprévisibles (météo, maladies, etc.).

Quatre combinaisons de b et σ sont étudiées, avec les paramètres communs : capacité $\ell = 100$, taux $\lambda = 0{,}3$, bruit $\sigma_0 = 1$, volume initial $X_0 = 10$.

Deux lois de dérive.

$$\begin{aligned} b_1(x) &= \lambda(\ell - x) && \text{(linéaire : retour vers } \ell\text{)} \\ b_2(x) &= \lambda x(\ell - x) && \text{(logistique : croissance nulle en 0 et en } \ell\text{)} \end{aligned}$$

Deux régimes de bruit.

$$\begin{aligned} \sigma_a(x) &= \sigma_0 && \text{(constant : perturbations indépendantes du volume)} \\ \sigma_b(x) &= \sigma_0 \cdot x && \text{(proportionnel : perturbations amplifiées par le volume)} \end{aligned}$$

Les quatre scénarios résultants sont notés 1a, 1b, 2a, 2b.

2.2 Schéma de simulation

L'EDS (1) est approchée par discrétisation temporelle avec pas $h > 0$:

$$\tilde{X}_{(k+1)h} = \tilde{X}_{kh} + b(\tilde{X}_{kh}) \cdot h + \sigma(\tilde{X}_{kh}) \cdot \sqrt{h} \cdot \varepsilon_{k+1}, \quad \varepsilon_{k+1} \sim \mathcal{N}(0,1). \tag{2}$$

La racine $\sqrt{h}$ traduit la propriété du brownien : $W_{(k+1)h} - W_{kh} \sim \mathcal{N}(0,h)$.

La stabilité du schéma dépend du pas h. Pour la dérive linéaire, la partie déterministe de (2) est stable si et seulement si $h < 2/\lambda$. De même, pour la dérive logistique, la condition est $h < 2/(\lambda\ell)$. Au-delà de ces seuils, le schéma diverge numériquement.

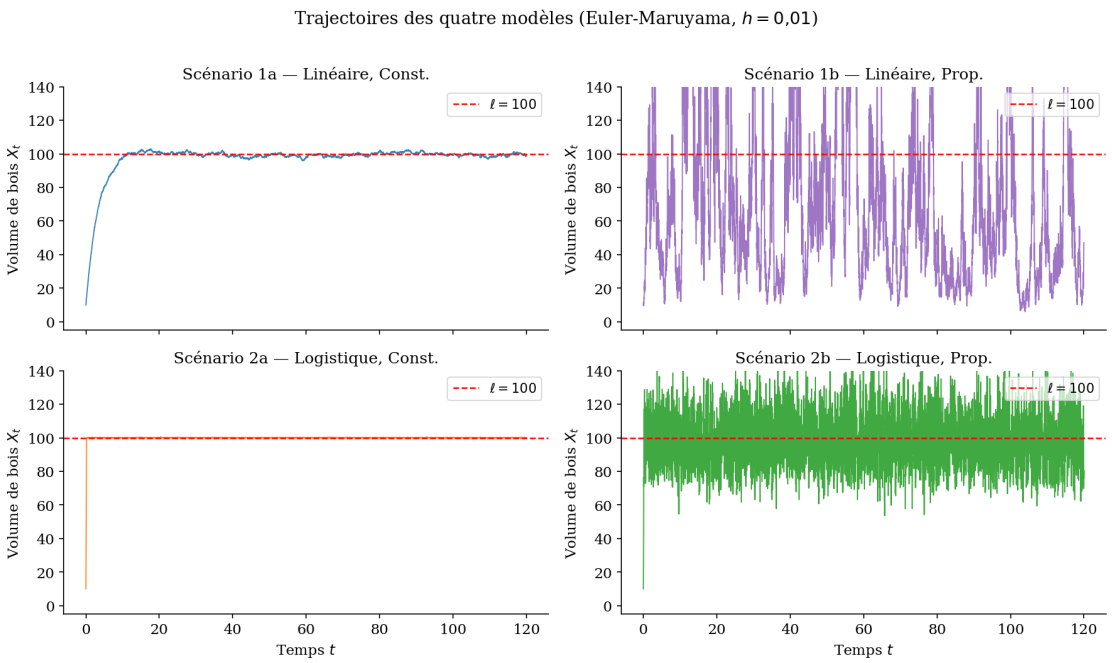

Figure 1: Trajectoires simulées des quatre modèles sur $[0, 120]$ avec $h = 0{,}01$. Tous convergent vers $\ell = 100$ (pointillé rouge), avec des régimes de fluctuations distincts. Le scénario 2b (logistique, bruit proportionnel) présente les oscillations les plus amples.

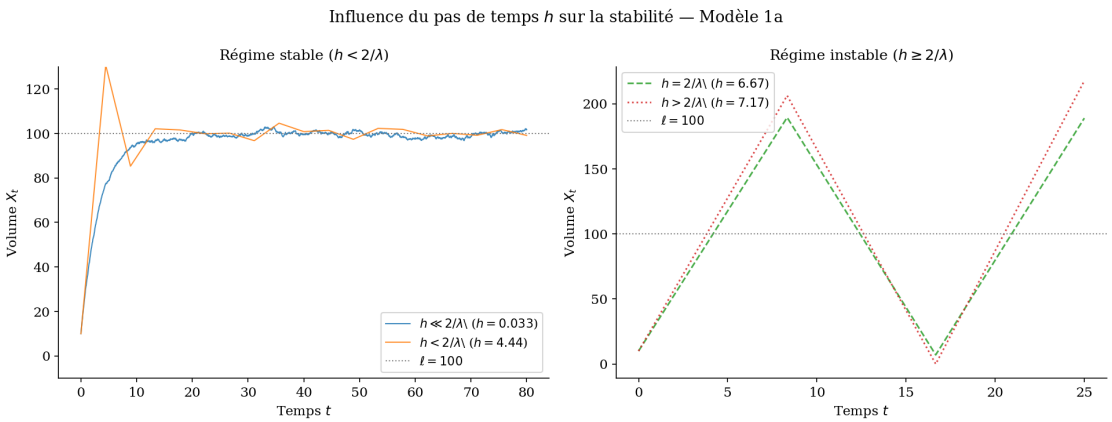

Figure 2: Influence du pas de temps h sur la stabilité numérique (modèle 1a). À gauche : régime stable pour $h < 2/\lambda$. À droite : instabilité et divergence pour $h \geq 2/\lambda$, conformément à la condition théorique.

3 Lois stationnaires

3.1 Comportement à long terme et théorème ergodique

La loi stationnaire d'un processus est la distribution vers laquelle ses états convergent sur le long terme. Elle est caractérisée par sa densité ρ_b, solution de l'équation de Fokker-Planck stationnaire associée à (1).

Théorème 3.1 (Théorème ergodique)**.** *Sous des conditions d'ergodicité vérifiées par nos modèles, pour toute fonction f intégrable par rapport à ρ_b :*

$$\frac{1}{T}\int_0^T f(X_t)\,\mathrm{d}t \xrightarrow[T\to\infty]{p.s.} \int_{\mathbb{R}} f(x)\,\rho_b(x)\,\mathrm{d}x.$$

Ce résultat justifie l'estimation de ρ_b par simulation : l'histogramme des valeurs (X_t) sur un long horizon converge vers la densité stationnaire. En pratique, les premières unités de temps sont ignorées (période de chauffe) pour s'affranchir de la condition initiale.

3.2 Estimation et résultats

Deux approches ont été comparées : estimation par plusieurs trajectoires courtes indépendantes, et estimation par une unique trajectoire longue. Les deux convergent vers la même loi limite (par ergodicité) ; la seconde est plus fidèle à l'esprit du théorème et moins coûteuse.

Pour la dérive linéaire avec bruit constant (scénario 1a), la densité stationnaire peut être calculée analytiquement. En intégrant l'équation de Fokker-Planck avec b_1 et σ_a constants, on obtient que ρ_{b_1} est proportionnelle à $\exp(-(x-\ell)^2\lambda/\sigma_0^2)$, ce qui identifie la loi stationnaire comme une loi normale :

$$\rho_{b_1}(x) = \mathcal{N}\left(\ell,\ \frac{\sigma_0^2}{2\lambda}\right). \tag{3}$$

La moyenne est ℓ (la forêt revient vers sa capacité) et la variance $\sigma_0^2/(2\lambda)$ traduit l'équilibre entre le rappel λ et le bruit σ_0.

Pour les autres scénarios, aucune expression analytique simple n'existe et l'estimation est purement numérique.

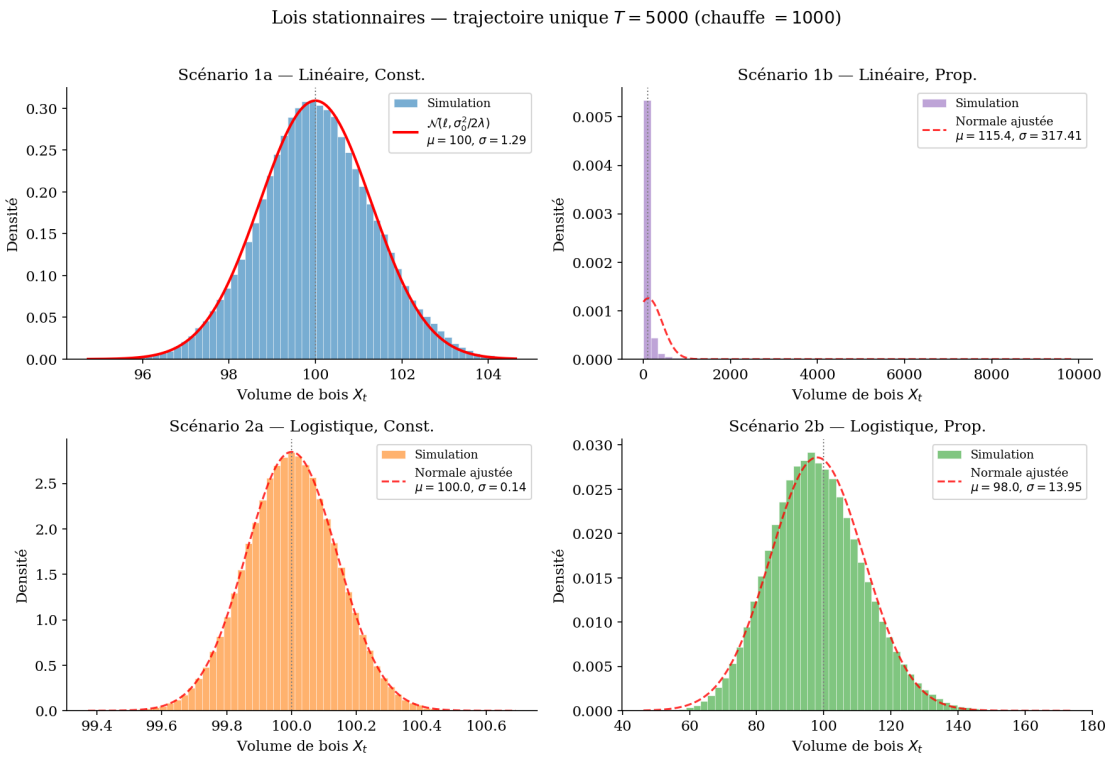

Figure 3: Lois stationnaires estimées par simulation longue ($T = 5000$, chauffe de 1000) pour les quatre modèles. Pour le scénario 1a, la courbe rouge est la densité normale théorique $\mathcal{N}(\ell,\, \sigma_0^2/2\lambda)$, confirmée par la simulation. Les autres modèles superposent une normale ajustée aux données à titre de comparaison.

4 Contrôle optimal avec dynamique connue

4.1 Formulation du problème

Lorsqu'une coupe intervient alors que le volume vaut y, le gestionnaire récupère un volume $y - y_0$ (où y_0 est le volume laissé après coupe) et paie les frais fixes c. Le gain net est :

$$g(y) = y - y_0 - c.$$

Une **stratégie à seuil** de niveau y consiste à laisser la forêt croître librement depuis y_0 jusqu'à ce qu'elle atteigne y, puis à couper. Le critère à maximiser est le **profit moyen par unité de temps** sur le long terme :

$$\Phi(b) = \sup_{y > y_0 + c} \liminf_{T \to \infty} \frac{1}{T} \mathbb{E}\left[\sum_{n : \tau_n \le T} g(y) \right],$$

où τ_n désigne le n-ième instant de coupe.

4.2 Le seuil optimal et la fonction ξ_b

L'intuition du résultat d'optimalité est simple. En notant $\xi_b(y) = \mathbb{E}[\tau_y \mid X_0 = y_0]$ le **temps moyen d'un cycle** (temps pour croître de y_0 à y), le profit par cycle vaut $g(y)$ et dure en moyenne $\xi_b(y)$. Le profit moyen par unité de temps de la stratégie à seuil y est donc $g(y)/\xi_b(y)$.

Proposition 4.1. *La valeur optimale est* $\Phi(b) = \sup_y g(y)/\xi_b(y)$, *atteinte par la stratégie à seuil* $y^* = \arg\max_y g(y)/\xi_b(y)$.

La fonction ξ_b est calculée numériquement à partir de la loi stationnaire via la formule (3.4) de [1], par double intégration par trapèzes.

4.3 Résultats numériques

La Figure 4 montre le rendement $g(y)/\xi_b(y)$ en fonction du seuil y pour les quatre modèles. La forme unimodale de ces courbes confirme l'existence d'un seuil optimal unique dans chaque cas.

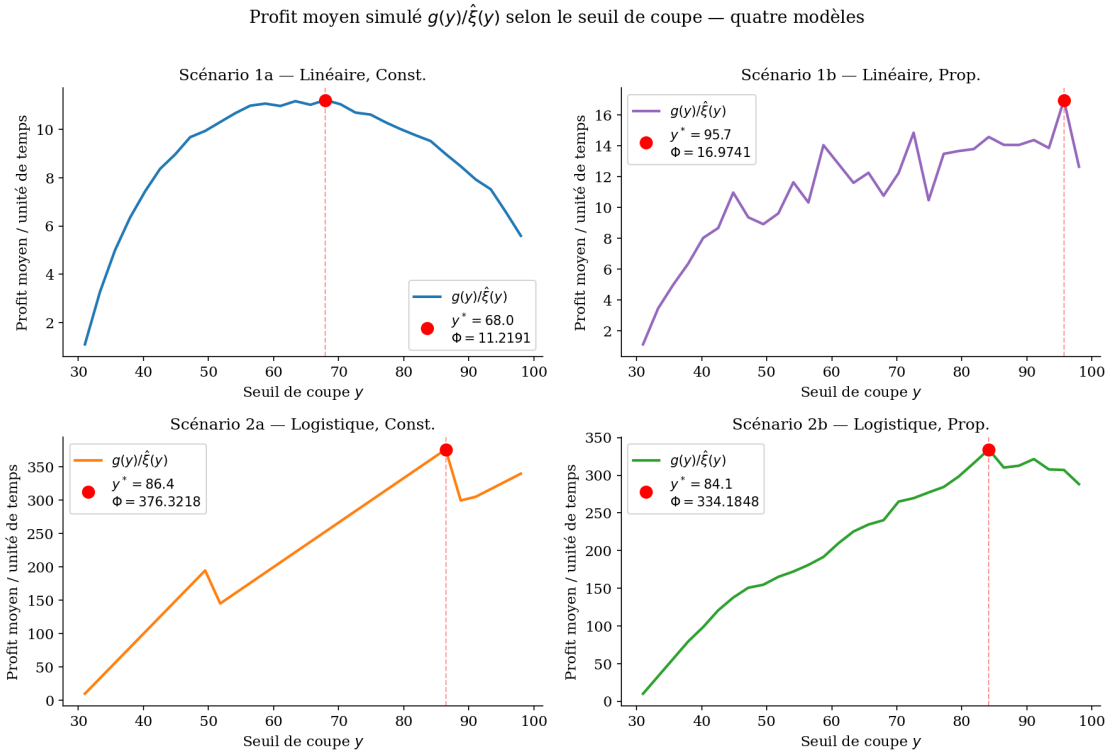

Figure 4: Profit moyen par unité de temps $g(y)/\hat{\xi}(y)$ en fonction du seuil de coupe y, estimé par simulation pour les quatre modèles. Le point rouge indique le seuil optimal y^* identifié numériquement.

L'optimalité de y^* est vérifiée en comparant les profits obtenus avec les seuils $y^* - 10$, y^* et $y^* + 10$: le seuil calculé produit bien le meilleur résultat dans tous les scénarios.

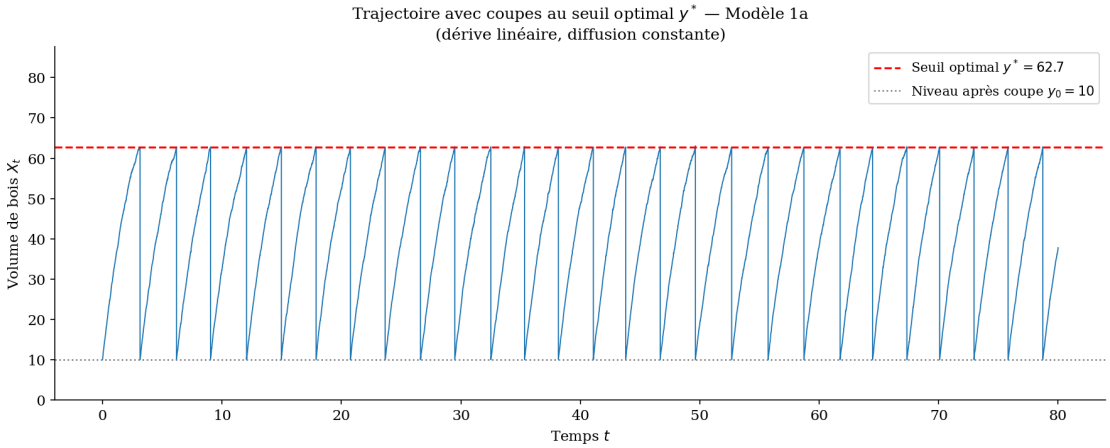

Figure 5: Évolution du volume de bois X_t sous la stratégie à seuil optimal y^* (scénario 1a). Les chutes verticales sont les instants de coupe ; la forêt repart à chaque fois de y_0.

5 Apprentissage par renforcement

5.1 Le problème central : apprendre sans connaître b

Dans la réalité, la fonction de dérive b est inconnue. Le gestionnaire ne peut qu'observer l'évolution de la forêt au fil du temps. Or y^* dépend de b via ξ_b : sans estimer b (ou plus précisément ρ_b), on ne peut pas calculer y^*.

Une stratégie naïve consisterait à d'abord observer la forêt librement pendant une longue période pour estimer ρ_b, puis à appliquer définitivement le seuil estimé. Cette approche a un défaut rédhibitoire : dès que l'on commence à couper à un seuil $\hat{y}$, le processus ne dépasse jamais $\hat{y}$ en phase d'exploitation, et l'on ne peut plus rien apprendre au-delà. Si $\hat{y}$ est trop bas, l'erreur est irréversible.

La solution est d'alterner des **phases d'exploration** (on observe la forêt croître au-delà de $\hat{y}$, sans couper) et des **phases d'exploitation** (on coupe au seuil estimé courant). L'exploration enrichit continuellement la connaissance de ρ_b, permettant d'améliorer $\hat{y}$ au fil du temps.

5.2 Estimation de la loi stationnaire et de ξ_b

Durant les phases d'exploration, on accumule un échantillon (X_i) du processus non contrôlé. La densité ρ_b est estimée par la méthode `gaussian_kde` de `scipy.stats`, qui ajuste automatiquement la bande passante (règle de Silverman). Cette densité estimée $\hat{\rho}$ est ensuite substituée à ρ_b dans la formule de ξ_b pour obtenir $\hat{\xi}$, par double

intégration numérique :

$$\hat{\xi}(y) = 2 \int_{y_0}^{y} \frac{\int_{y_0}^{v} \hat{\rho}(z)\,\mathrm{d}z}{\hat{\rho}(v)\,\sigma^2(v)}\,\mathrm{d}v.$$

Le seuil estimé est alors :

$$\hat{y}^* = \arg\max_{y \in \mathcal{Y}} \frac{g(y)}{\hat{\xi}(y)},$$

où $\mathcal{Y}$ est une grille de seuils candidats.

5.3 Stratégie d'alternance et équilibre exploitation-exploration

La clé de l'algorithme est le rythme d'alternance entre exploration et exploitation. Si l'on explore trop, on n'exploite pas assez et le profit cumulé est faible. Si l'on exploite trop, $\hat{y}^*$ ne converge pas vers y^* et le profit reste sous-optimal. Il faut équilibrer ces deux sources de perte, appelées **regret**.

L'article [1] montre que la règle optimale est de passer un temps $S_T \asymp T^{2/3}$ en exploration jusqu'à l'horizon T. En pratique, on entre en phase d'exploration si $S_t \leq m \cdot t^{2/3}$ (avec $m > 0$ un paramètre), et en exploitation sinon.

Proposition 5.1 (Taux de regret optimal, [1])**.** *Avec la stratégie ci-dessus, le regret moyen par unité de temps satisfait :*

$$\Phi(b) - \frac{\textit{profit cumulé}}{T} = O\big(T^{-1/3}\big)\,.$$

Ce taux résulte de l'équilibre entre le regret d'exploration (d'ordre $S_T/T \asymp T^{-1/3}$) et le regret d'exploitation dû à l'estimation imparfaite de ξ_b (d'ordre $T^{-1/3}$ également pour $S_T \asymp T^{2/3}$).

5.4 Algorithme

Algorithme 1 Apprentissage par renforcement pour la gestion de forêt

Require: Horizon T, grille $\mathcal{Y}$, pas h, paramètres y_0, c, ζ, m

$t \leftarrow 0$, $S \leftarrow 0$, profit $\leftarrow 0$, échantillon $\leftarrow \emptyset$, $\hat{y}^* \leftarrow$ médiane de $\mathcal{Y}$
while $t < T$ **do**
  if $S \leq m \cdot \max(t, 1)^{2/3}$ **then** *// condition d'exploration*
    Simuler le processus librement de y_0 jusqu'à ζ, puis laisser redescendre
    Ajouter les observations à l'échantillon ; incrémenter t et S
    Aucun gain encaissé
    if échantillon suffisamment grand **then**
      Estimer $\hat{\rho}$ par `gaussian_kde` sur l'échantillon
      Calculer $\hat{\xi}(y)$ par double intégration de $\hat{\rho}$
      $\hat{y}^* \leftarrow \arg\max_{y \in \mathcal{Y}} \; g(y)/\hat{\xi}(y)$
    end if
  else *// phase d'exploitation*
    Simuler un cycle de coupe de y_0 jusqu'au seuil $\hat{y}^*$
    profit $\leftarrow$ profit $+ g(\hat{y}^*)$; incrémenter t
  end if
end whilereturn profit$/t$, $\hat{y}^*$

5.5 Corrections apportées et difficultés d'implémentation

Le développement de cet algorithme a nécessité plusieurs corrections par rapport à une implémentation initiale incorrecte.

Séparation stricte exploration/exploitation. La phase d'exploration doit laisser la forêt évoluer *librement* jusqu'à ζ puis redescendre naturellement, sans aucune coupe et sans aucun gain encaissé. Une première version utilisait une simple simulation jusqu'à ζ avec coupe à l'arrivée, faussant à la fois le calcul du profit et la collecte de données.

Seuil initial neutre. Partir d'un seuil médian plutôt que maximal évite des premiers cycles d'exploitation avec un seuil arbitrairement mauvais avant que l'estimation soit fiable.

Stabilité numérique de $\hat{\xi}$. Le calcul de $\hat{\xi}$ par double intégration implique de diviser par $\hat{\rho}$, qui peut être très proche de zéro loin du mode. Un plancher numérique $\hat{\rho}_{\text{sûr}} = \max(\hat{\rho}, 10^{-5})$ a été introduit pour éviter les divergences.

5.6 Résultats

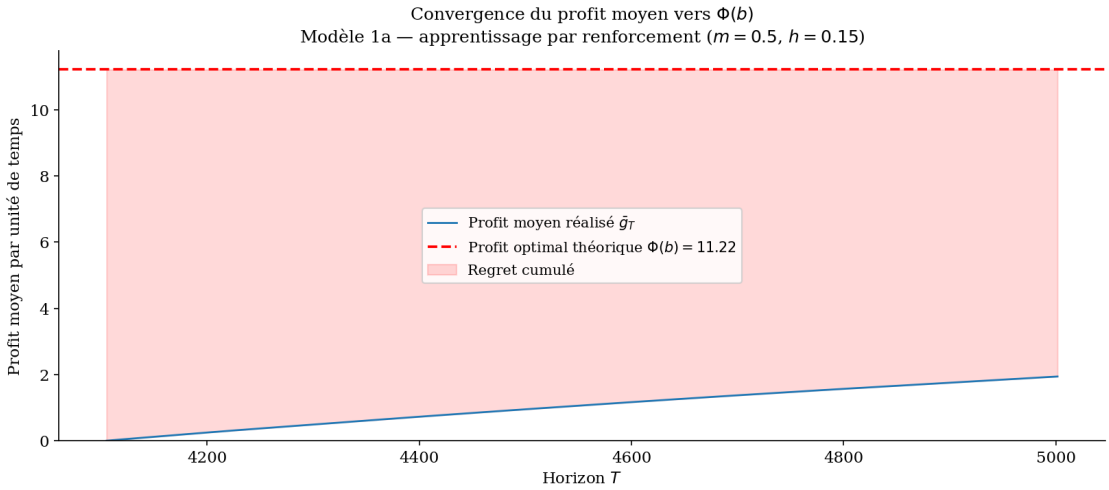

Figure 6: Convergence du profit moyen réalisé par l'algorithme d'apprentissage par renforcement vers $\Phi(b)$ (pointillé rouge). La zone rouge représente le regret cumulé qui se résorbe progressivement. Scénario 1a, $m = 0{,}5$, $h = 0{,}15$.

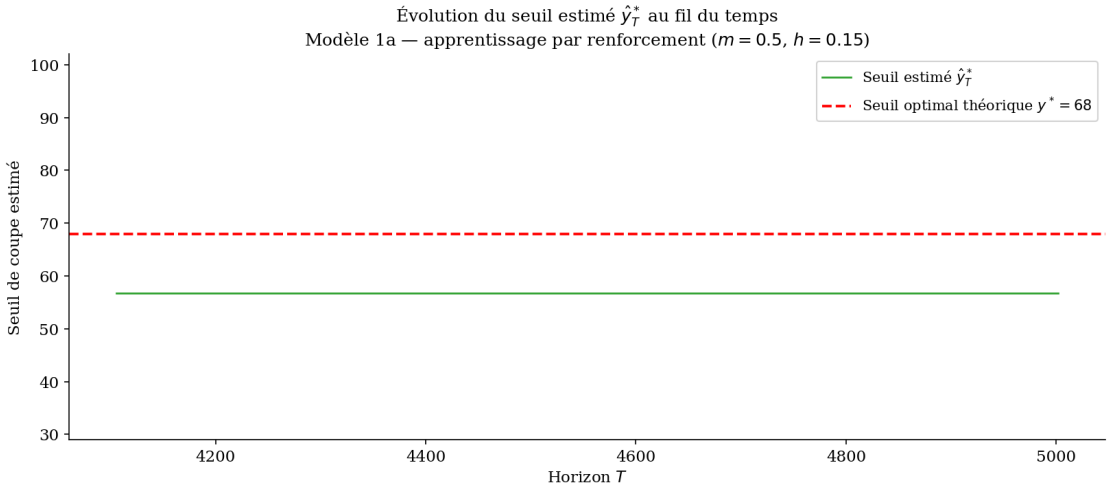

Figure 7: Évolution du seuil estimé $\hat{y}_T^*$ au fil du temps. La ligne rouge indique le seuil optimal théorique y^*. Le seuil estimé converge progressivement après la phase d'apprentissage initiale.

Les figures 6 et 7 illustrent la convergence de l'algorithme : le profit moyen se rapproche de $\Phi(b)$ et le seuil estimé converge vers y^*, conformément au taux théorique $O(T^{-1/3})$.

6 Organisation du groupe et retour d'expérience

6.1 Organisation du travail

Le groupe (Paul Laborde, Thomas Gamot, Paul Da Silva Fernandes, Oscar Huchet, Olivier Dayraut) a organisé son travail en suivant la progression naturelle du projet.

Une première phase collective a permis de prendre en main le sujet : lecture de l'article de référence, compréhension des modèles et premières simulations. Cette étape a été essentielle pour que chacun s'approprie les enjeux avant de se spécialiser.

Dans un second temps, le groupe s'est réparti par affinités : certains membres ont approfondi la partie mathématique (lois stationnaires, formule de ξ_b, calcul du seuil optimal), d'autres se sont concentrés sur l'implémentation et l'optimisation du code Python.

La conception et le débogage de l'algorithme d'apprentissage par renforcement ont ensuite été menés collectivement, les erreurs conceptuelles détectées nécessitant des discussions de fond sur l'article.

6.2 Difficultés rencontrées

Lecture de l'article scientifique. L'article de Christensen et Strauch, destiné à un public spécialiste, a représenté un obstacle notable. La formule de ξ_b et son interprétation probabiliste comme temps moyen d'un cycle ont nécessité plusieurs séances de travail en groupe.

Implémentation de ξ_b. Le calcul par double intégration numérique est sensible aux instabilités (division par des densités proches de zéro). L'introduction d'un plancher et le passage à `gaussian_kde` pour l'estimation de ρ_b ont amélioré la robustesse.

Erreur conceptuelle sur l'exploration. La distinction entre observation sans gain (exploration) et coupe avec gain (exploitation) semblait évidente en théorie mais a été difficile à traduire correctement en code. Une première implémentation encaissait des gains pendant l'exploration, ce qui biaisait les résultats sans que l'erreur soit immédiatement visible.

Temps de calcul. Les simulations longues, combinées au calcul répété de $\hat{\xi}$ sur une grille, ont engendré des temps d'exécution significatifs. La vectorisation avec `numpy` et le choix d'un pas h plus large pour la phase d'apprentissage ont permis de rendre les calculs praticables.

7 Conclusion

Ce projet a permis de mettre en œuvre, de bout en bout, une approche d'apprentissage par renforcement pour le problème de gestion optimale d'une forêt. La progression chronologique – simulation, contrôle avec dynamique connue, apprentissage sans connaissance a priori – reflète fidèlement le déroulement réel du travail et illustre comment des outils issus du calcul stochastique, de l'optimisation et de l'apprentissage automatique peuvent être combinés pour résoudre un problème concret.

Le résultat principal, la convergence du profit avec un regret en $O(T^{-1/3})$, est non seulement un résultat théorique de l'article de référence, mais aussi un fait observé numériquement dans nos simulations. La nécessité de corriger l'implémentation initiale de l'algorithme a par ailleurs été l'occasion de comprendre plus finement les subtilités conceptuelles du dilemme exploration-exploitation.

Plusieurs pistes restent ouvertes : étude de la sensibilité au paramètre m, comparaison entre les quatre modèles pour l'algorithme d'apprentissage, ou encore exploration du comportement pour des horizons T plus grands permettant d'observer plus clairement le taux de convergence.

References

[1] S. Christensen et C. Strauch, *Nonparametric learning for impulse control problems*, arXiv:1909.09528v3, janvier 2022.

Annexe — Pseudo-code des fonctions clés

Algorithme 2 Simulation d'une trajectoire (discrétisation d'EDS)

Require: N, h, fonctions b, σ, valeur initiale x_0

```
X[0] ← x_0
for k = 0 à N − 1 do
    Tirer ε ∼ N(0, 1)
    X[k + 1] ← X[k] + b(X[k]) · h + σ(X[k]) · √h · ε
    X[k + 1] ← max(X[k + 1], 0)
end forreturn X
```

Algorithme 3 Estimation de $\hat{\xi}$ par Gaussian KDE et intégration numérique

Require: Grille $\mathcal{Y}$, échantillon (X_i), fonction σ

$\hat{\rho} \leftarrow$ `gaussian_kde`$((X_i))$ évalué sur $\mathcal{Y}$

$\hat{\rho}_{\text{sûr}} \leftarrow \max(\hat{\rho},\, 10^{-5})$

$I(y) \leftarrow \int_{y_0}^{y} \hat{\rho}(z)\,\mathrm{d}z$ *// trapèzes cumulatifs*

$\hat{\xi}(y) \leftarrow 2\int_{y_0}^{y} \dfrac{I(v)}{\hat{\rho}_{\text{sûr}}(v)\,\sigma^2(v)}\,\mathrm{d}v$ *// trapèzes cumulatifs* **return** $\hat{\xi}$

Algorithme 4 Cycle d'exploration sans coupe

Require: Départ y_0, borne ζ, fonctions b, σ, pas h

$x \leftarrow y_0$, chemin $\leftarrow [y_0]$, $t \leftarrow 0$

while $x < \zeta$ **do**

  $x \leftarrow x + b(x)h + \sigma(x)\sqrt{h} \cdot \mathcal{N}(0,1)$; $t \leftarrow t + h$; ajouter x au chemin

end while

while $x > y_0$ **do** *// retour naturel sans couper*

  $x \leftarrow x + b(x)h + \sigma(x)\sqrt{h} \cdot \mathcal{N}(0,1)$; $t \leftarrow t + h$; ajouter x au chemin

end whilereturn t, chemin *// aucun gain*